

인공지능 데이터 전처리 결과서

가입 고객 이탈 예측 시스템

IBM Telco Customer Churn Dataset 기반

SKN32-2nd-4Team

2026-06-22 오한빈

1. 개요

본 문서는 IBM Telco Customer Churn 데이터셋(7,043 건, 21 개 컬럼)을 분석 및 모델 학습에 적합한 형태로 가공한 전처리 과정과 그 결과를 정리한다. 전처리는 분석 A(세그먼트 경계 탐지)·분석 B(위험속성 탐지)·서브트랙 Q(risk_count)와 예측모델 학습 전 단계에서 공통으로 수행되며, 모든 단계는 재현 가능한 코드(segment_discovery/src/preprocessing.py, shared/data_loader.py, churn_prediction/src/feature_engineering.py)로 구현되어 있다.

1.1 데이터셋 개요

항목	값
데이터 출처	IBM Telco Customer Churn (blastchar, Kaggle 공개 데이터셋)
원본 레코드 수	7,043 건
원본 컬럼 수	21 개 (식별자 1, 범주형 16, 수치형 3, 타깃 1)
타깃 변수	Churn (이탈 여부, Yes/No)
원본 이탈률	1,869 건 / 7,043 건 = 26.5%

표 1-1. 원본 데이터셋 개요

1.2 전처리 파이프라인 구조

핵심 설계 원칙은 pandas DataFrame 하나(df)를 파이프라인 전체에서 유지하는 것이다. customerID 등 식별 컬럼을 위한 별도 자료구조를 두지 않고, 모델 입력(X)은 필요한 시점에 df에서 컬럼만 선택하여 구성한다. 예측 결과 역시 df에 새 컬럼으로 재결합하여 손해추정 등 후속 분석에 바로 활용할 수 있도록 한다.

데이터 누수 방지 원칙: 세그먼트 경계, 더미 컬럼 목록, 스케일러의 fit은 전부 Train 데이터로만 수행하고 Test/추론 데이터에는 적용(transform)만 한다. 이 원칙은 segment_discovery/src/preprocessing.py와 churn_prediction/src/feature_engineering.py 양쪽에서 코드로 강제된다.

2. 결측치 및 데이터 정합성 처리

2.1 TotalCharges 결측치 처리

원본 데이터에서 TotalCharges 컬럼은 문자열(object) 타입으로 저장되어 있으며, 공백 문자열 형태의 결측치 11 건이 존재한다. pd.to_numeric(errors='coerce')로 숫자형 변환 후 결측치를 0 으로 대체하였다.

검증 항목	결과
결측치 건수	11 건 (전체의 0.16%)
결측 행의 tenure 값	전부 0 (신규 가입 당일, 아직 청구 이력 없음)
결측 행의 Churn 값	전부 'No' (비이탈) — 11 건 모두 일치
대체 처리 방법	0 으로 대체 (신규 가입자의 누적 청구액이 0 인 것은 타당)

표 2-1. TotalCharges 결측치 검증 결과

결측치가 무작위가 아니라 tenure=0 이라는 구조적 원인에서 발생했음을 확인하였으며, 단순 대체가 아니라 원인 추적 후 처리한 결과이다.

2.2 중복 정보 통합 (다중공선성 방지)

'No internet service' 및 'No phone service' 값은 'No'로 통합하였다. 이는 단순한 정보 손실 방지 목적이 아니라, 해당 값이 InternetService_No / PhoneService_No 컬럼과 100% 중복되어 원-핫 인코딩 시 다중공선성을 유발하기 때문이다.

대상 컬럼	변환 전 'No internet service' 건수	변환 후
OnlineSecurity	1,526 건	0 건
OnlineBackup	1,526 건	0 건
DeviceProtection	1,526 건	0 건
TechSupport	1,526 건	0 건
StreamingTV	1,526 건	0 건
StreamingMovies	1,526 건	0 건

표 2-2. InternetService 관련 중복정보 통합 결과 (1,526 명 = 전체의 21.7%)

대상 컬럼	변환 전 'No phone service' 건수	변환 후
-------	----------------------------	------

MultipleLines	682 건	0 건
---------------	-------	-----

표 2-3. PhoneService 관련 중복정보 통합 결과 (682 명 = 전체의 9.7%)

3. Train/Test 분할

계층화 분할(stratify=Churn)을 적용하여 70:30 비율로 Train/Test 를 분할하였다. 계층화 분할의 목적은 이탈 비율(26.5%)이 양쪽 데이터셋에 동일하게 유지되도록 하여, 분할로 인한 우연한 클래스 불균형 차이가 평가 결과를 왜곡하지 않도록 하는 것이다.

구분	레코드 수	이탈률
Train	4,930 건 (70.0%)	26.53%
Test	2,113 건 (30.0%)	26.55%
전체	7,043 건	26.54%

표 3-1. Train/Test 분할 결과 (실행 ID: 20260622_143947 기준)

Train/Test 간 이탈률 차이가 0.02%p 에 불과하여 계층화 분할이 정확히 작동함을 확인하였다.

3.1 Train 데이터 주요 수치형 변수 분포

변수	평균	표준편차	최솟값	중앙값	최댓값
tenure (개월)	32.47	24.65	0	29	72
MonthlyCharges	64.95	30.24	18.40	70.58	118.75

표 3-2. Train 데이터 수치형 변수 기술통계

4. 변수 인코딩

4.1 이진 범주형 변수

Partner, Dependents, PhoneService, PaperlessBilling 등 Yes/No 이진값을 갖는 컬럼은 .map({'Yes':1,'No':0})으로 단순 매핑하였다.

4.2 다중 범주형 변수 (원-핫 인코딩)

gender, MultipleLines, InternetService, OnlineSecurity, OnlineBackup, DeviceProtection, TechSupport, StreamingTV, StreamingMovies, Contract, PaymentMethod 등 다중 범주형 변수는 원-핫 인코딩을 적용하였다. 더미 컬럼 목록은 Train 데이터 기준으로만 생성(fit)하고, Test/추론 데이터에는 동일 목록을 강제 정렬(reindex)하여 적용한다.

항목	값
Train 기준 생성된 더미 컬럼 수	42 개
feature_cols_12 (1·2 단계 모델 입력, segment 제외)	34 개
feature_cols_3 (3 단계 모델 입력, segment 포함)	38 개

표 4-1. 인코딩 후 피처 구성

⚠ 단계별 입력 피처가 다름: *segment* 컬럼은 분석 A 가 데이터 기반으로 발견한 결과물이므로, '사람이 정한 단순 함수형태'를 대표하는 1 단계(로지스틱 회귀) 및 2 단계(XGBoost 비교군) 입력에는 포함하지 않는다. 3 단계(메인 모델) 입력에만 포함하여 분석 A 발견의 기여도를 검증할 수 있도록 한다.

4.3 세그먼트(segment) 컬럼 — 분석 A 산출물의 인코딩

분석 A(가지치기 회귀나무 기반 경계 탐지)가 데이터 기반으로 발견한 생애주기 구간 경계를 적용하여 *segment* 컬럼을 생성하고, Contract 와 동일하게 다중 범주형으로 원-핫 인코딩하였다.

세그먼트	tenure 구간(개월)	Train 표본수	이탈률
segment_0	0 ~ 10.5	1,369 건	49.67%
segment_1	10.5 ~ 22.5	749 건	29.77%
segment_2	22.5 ~ 54.5	1,534 건	19.23%
segment_3	54.5 이상	1,278 건	8.61%

표 4-2. 세그먼트 경계 및 분포 (분석 A 산출물, K=4)

경계값(10.5, 22.5, 54.5 개월)은 가지치기 회귀나무를 통해 데이터가 직접 탐색하였으며, 세그먼트단독 AUC 0.7223(95% CI [0.7034, 0.7373])과 순열검정 $p=0.0000$ 으로 통계적 실재성이 검증되었다. 검증 절차의 상세 내용은 인공지능 학습 결과서를 참조한다.

4.4 연속형 변수 스케일링

tenure, MonthlyCharges, TotalCharges 는 모델 계열에 따라 두 가지 방식으로 처리한다.

- 트리 기반 모델(2-3 단계 XGBoost): 원본 값을 그대로 사용 (트리 모델은 스케일에 불변)
- 선형/MLP 모델(1 단계 로지스틱 회귀, 보조 MLP): StandardScaler 를 Train 데이터로 fit 하고 Test/추론 데이터에는 transform 만 적용

5. 전처리 검증 결과

5.1 데이터 누수 방지 검증

아래 항목에 대해 Train 데이터로만 규칙(rule)을 학습(fit)하고 Test/추론 데이터에는 적용(transform)만 한다는 원칙이 코드 수준에서 지켜지는지 자동 테스트로 검증하였다(tests/test_feature_transformer.py).

검증 항목	검증 방법	결과
세그먼트 경계 fit	Train 으로만 탐색, Test 는 적용만	통과
더미 컬럼 목록 fit	Train 기준 컬럼만 dummy_columns 에 포함	통과
스케일러 재학습 여부	추론 시 scaler.fit() 미호출 확인	통과
학습 시점 없던 범주값 처리	reindex(fill_value=0)으로 안전 처리	통과
tenure 가 학습 최댓값 초과 시	마지막 세그먼트로 안전 분류 (NaN 미발생)	통과

표 5-1. 데이터 누수 방지 자동 검증 결과 (전체 88 개 테스트 중 발체)

5.2 운영 환경 적용 — 학습/추론 일원화

전처리 규칙(더미 컬럼 목록, 스케일러 파라미터, 세그먼트 경계)은 FeatureTransformer 객체로 직렬화(feature_transformer.pkl)되어 저장된다. 추론 단계(predict.py)는 이 객체를 그대로 불러와 재사용하며, 별도로 규칙을 재학습하지 않는다. 이를 통해 학습 시점과 추론 시점의 피쳐 형식이 항상 일치함을 보장한다.

스냅샷 데이터의 한계: 본 데이터셋은 가입일·이탈일 등 절대 날짜 정보가 없는 횡단면 스냅샷이다. 따라서 추론 시 '특정 날짜 이후 가입자'와 같은 절대 시점 필터링은 불가능하며, tenure(경과월) 또는 segment 기준으로만 범위를 구분할 수 있다. 이 한계는 전처리 단계뿐 아니라 분석 A·B·서브트랙 Q 및 예측모델 전체에 적용된다.

6. 결론

본 전처리 과정은 (1) 결측치의 구조적 원인을 추적한 후 처리, (2) 다중공선성을 유발하는 중복 정보를 의도적으로 통합, (3) 데이터 누수를 코드 수준에서 차단, (4) 분석 A의 데이터 기반 발견(segment)을 모델별로 명시적으로 분기하여 적용하는 네 가지 원칙 위에서 수행되었다. 모든 처리 단계는 재현 가능한 코드와 자동화된 회귀테스트로 검증되었으며, 처리 결과는 인공지능 학습 결과서의 입력으로 그대로 연계된다.