

# 인공지능 학습 결과서

생애주기 세그먼트·위험속성·위험신호 분석 체계와 이원화 MLOps 아키텍처를 결합한 고객  
이탈 예측 시스템

**SKN32-2nd-4Team**

2026-06-22 | 실행 ID: 20260622\_171419 오한빈

## 1. 개요

본 문서는 IBM Telco Customer Churn 데이터셋을 기반으로 수행한 분석 체계(분석 A·분석 B·서브트랙 Q)와 예측모델(1·2·3 단계 비교 구조) 학습 결과를 정리한다. 핵심 설계 철학은 '데이터가 결정하도록 하고, 사람의 개입은 최소화한다'이며, 세그먼트 경계·위험속성·검증 반복횟수·안전 마진까지 가능한 모든 지점에서 사람의 직감 대신 데이터/통계적 검증이 값을 결정하도록 설계하였다.

### 1.1 분석 체계 구조

예측모델의 본질은 절대 날짜가 없는 스냅샷 데이터의 한계로 인해 '몇 개월 후 이탈할지 예측'이 아니라 '현재 속성 기준 이탈 위험도 점수'를 산출하는 것이다. 분석 A(생애주기)와 분석 B(속성)는 이 점수가 왜 높은지 설명하는 역할을 하며, 서브트랙 Q는 이들과 독립적으로 위험신호 누적 효과를 정량화한다.

| 구성요소   | 핵심 질문                | 방법론                                      |
|--------|----------------------|------------------------------------------|
| 분석 A   | 언제(생애주기상 어느 구간) 위험한가 | 가지치기 회귀나무 + 순열검정 + 부트스트랩                 |
| 분석 B   | 왜(어떤 속성이) 위험한가       | 세그먼트별 가지치기 결정나무 + AUC/순열검정               |
| 서브트랙 Q | 위험신호를 몇 개 동시 보유했는가   | risk_count 집계 + 순열검정 + 부트스트랩             |
| 예측모델   | 종합 이탈 위험도 점수         | 로지스틱회귀(1 단계) / XGBoost(2·3 단계) / MLP(보조) |

표 1-1. 분석 체계 전체 구조

## 2. 분석 A — 생애주기 세그먼트 경계 탐지

### 2.1 절차

분석 A는 완전히 독립적인 네 절차로 구성되며, 각 절차는 서로 다른 질문에 답한다. ①은 경계를 직접 탐지하는 메인 절차와 그 좌표를 다른 알고리즘으로 사후 확인하는 보조 절차로 나뉜다.

| 절차 | 질문 | 방법 |
|----|----|----|
|----|----|----|

|                  |                        |                                                                                                                       |
|------------------|------------------------|-----------------------------------------------------------------------------------------------------------------------|
| ①-가 경계 탐지 (메인)   | 경계가 어디에 있는가            | 가지치기 회귀나무(DecisionTreeRegressor) — GridSearchCV 로 ccp_alpha 를 직접 탐색해 5-fold 교차검증 예측오차가 최소인 지점을 선택                     |
| ①-나 좌표 교차확인 (보조) | 그 좌표가 다른 알고리즘으로도 재현되는가 | 랜덤포레스트 200 개 트리 각각의 분기점(threshold)을 모아 빈도표를 만들고, 득표 상위 10 개와 ①-가의 경계 사이 거리( $\leq 2$ 개월)를 확인 — ccp_alpha 탐색에는 관여하지 않음 |
| ② 적절성 검증         | 그 경계가 실재하는가            | 세그먼트단독 AUC(RandomForestClassifier) + 순열검정(라벨 재배열)                                                                     |
| ③ 표본충분성 확인       | 측정이 안정적인가              | AUC 부트스트랩 신뢰구간(Out-of-Bag 방식)                                                                                         |

표 2-1. 분석 A 4 단계 절차

⚠ ccp\_alpha 는 ①-가(GridSearchCV)만 찾는다 — 랜덤포레스트는 경계 탐지 과정에 전혀 관여하지 않으며, ①-가가 이미 확정한 경계가 맞는지 사후에 다시 확인하는 별개 절차다. 단일 결정나무(①-가)는 좌표가 정밀하지만 alpha 탐색 그리드 설정에 미세하게 민감하고, 랜덤포레스트(①-나)는 여러 트리의 분기점 합의를 보여줘 좌표는 덜 정밀해도 시드 변경에 안정적이다 — 정밀도(①-가)와 안정성(①-나)의 역할 분담이며, 한쪽이 다른 쪽을 대체하지 않는다.

①이 머신러닝 기법이라는 사실이 ②(적절성)를 자동으로 보장하지 않으며, ②와 ③ 또한 서로 다른 질문(관련성 vs. 측정 안정성)에 답하는 별개 절차이다.

## 2.2 실행 결과

| 항목                 | 결과값                                            |
|--------------------|------------------------------------------------|
| 발견된 경계 (K=4)       | 10.5 개월 / 22.5 개월 / 54.5 개월                    |
| 가지치기 강도(ccp_alpha) | 0.001034 (5-fold 교차검증으로 자동 선택, alpha 후보 전체 탐색) |
| RF 보조검증 트리 개수      | 200 개 (데이터가 직접 결정)                             |
| 세그먼트단독 AUC         | 0.7223                                         |
| AUC 95% 신뢰구간       | [0.7034, 0.7373] (부트스트랩 40 회로 자동 수렴)           |
| 순열검정 p-value       | 0.0000 (60 회 반복으로 자동 수렴)                       |

표 2-2. 분석 A 실행 결과

반복횟수(부트스트랩 40 회, 순열검정 60 회)는 고정값이 아니라 순차적 조기중단(Sequential Early Stopping) 알고리즘이 매 실행마다 데이터 특성에 맞춰 자동으로 결정한 값이다. 관행적으로 쓰이던 고정값(부트스트랩 300 회, 순열검정 200 회) 대비 각각 7.5 배, 3.3 배의 비용 절감을 달성하였다.

⚠ "자동화가 항상 비용을 줄이는 것"은 아니다. ccp\_alpha 탐색은 비용을 아끼려 후보를 일부만 보면 alpha 값에 따라 결과 K 가 미세하게 흔들리는 그리드 민감성이 실측으로 확인되어, 오히려 전체 후보를 다 탐색하도록(비용을 늘리는 방향으로) 자동화하였다. 공통된 원칙은 "사람이 임의로 정하지 않는다"이며, "반복을 무조건 줄인다"가 아니다.

경계 좌표의 재현 안정성은 가지치기 회귀나무와는 독립적인 알고리즘(랜덤포레스트 200 개 트리의 분기점 투표)으로 교차확인되었다. 두 독립적 기준(예측오차 최소화 vs. 여러 트리의 합의)이 동일한 경계에서 수렴함을 확인하여, 발견된 경계가 특정 알고리즘에 의한 우연이 아님을 추가로 입증하였다.

## 2.3 세그먼트별 분포

| 세그먼트      | tenure 구간(개월) | Train 표본수 | 이탈률    |
|-----------|---------------|-----------|--------|
| segment_0 | 0 ~ 10.5      | 1,369 건   | 49.67% |
| segment_1 | 10.5 ~ 22.5   | 749 건     | 29.77% |
| segment_2 | 22.5 ~ 54.5   | 1,534 건   | 19.23% |
| segment_3 | 54.5 이상       | 1,278 건   | 8.61%  |

표 2-3. 세그먼트별 표본수 및 이탈률 (전체 평균 26.53% 대비 segment\_0 는 +23.1%p)

## 3. 분석 B — 세그먼트별 위험속성 탐지

분석 B 는 분석 A 가确定的한 세그먼트 내에서 가지치기 결정나무로 주요 위험속성을 탐지하고, 그 속성들만으로 만든 모델의 AUC 와 순열검정으로 적절성을 검증한다. 핵심 가치는 '같은 속성이라도 생애주기 맥락에 따라 영향력이 다르다'는 것의 실증이다.

위험속성의 개수 자체도 사람이 고정하지 않는다 — 결정나무의 feature\_importances\_ 중 0 보다 큰 속성을 전부 채택하며, 'top 2 개만' 같은 고정 개수 제한을 두지 않는다. 세그먼트마다 1~2 개로 자연스럽게 다르게 나오는 것은 이 자동 채택 방식의 결과다.

| 세그먼트 | Train 표본수 | 이탈률 | 주요 위험속성 | 속성기반 AUC | p-value | 95% 신뢰구간 |
|------|-----------|-----|---------|----------|---------|----------|
|------|-----------|-----|---------|----------|---------|----------|

|                     |       |        |                                                       |        |        |                  |
|---------------------|-------|--------|-------------------------------------------------------|--------|--------|------------------|
| 0 (0~10.5 개월)       | 1,369 | 49.67% | MonthlyCharges,<br>InternetService,<br>OnlineSecurity | 0.7575 | 0.0000 | [0.7223, 0.7811] |
| 1<br>(10.5~22.5 개월) | 749   | 29.77% | MonthlyCharges                                        | 0.7315 | 0.0000 | [0.6850, 0.7743] |
| 2<br>(22.5~54.5 개월) | 1,534 | 19.23% | Contract, MonthlyCharges                              | 0.7903 | 0.0000 | [0.7512, 0.8181] |
| 3 (54.5 개월+)        | 1,278 | 8.61%  | Contract, MonthlyCharges                              | 0.7677 | 0.0000 | [0.7115, 0.8040] |

표 3-1. 세그먼트별 위험속성 탐지 결과 (반복횟수: 전 세그먼트 부트스트랩 40 회, 순열검정 60 회로 자동 수렴)

신규 고객(segment\_0)은 서비스 구성(인터넷 서비스, 보안서비스 유무)이 핵심 위험신호인 반면, 중장기 고객(segment\_2, segment\_3)은 계약형태(Contract)가 핵심 위험신호로 전환된다. 이는 단일 모델의 SHAP 해석으로는 드러나지 않는 맥락별 실행 인사이트이다.

△ 분석 B 는 세그먼트 내부에서 다시 5-fold 교차검증을 수행하므로 실제 학습/검증 표본이 분석 A 보다 더 적다(세그먼트당 250~500 건 수준). 모든 세그먼트의 신뢰구간 폭이 0.04~0.06 수준으로 안정적임을 확인하여 표본부족 우려를 기각하였다.

## 4. 서브트랙 Q — risk\_count 위험신호 누적 분석

서브트랙 Q 는 분석 A·B 와 완전히 독립적으로, 분석 B 가 검증한 위험속성의 보유개수(risk\_count)를 집계하여 '여러 위험신호를 동시에 가진 고객 집단'을 정량화한다. 시너지(상승효과) 발견이 목적이 아니라 동시보유 집단의 정량화가 목적이다.

### 4.1 위험요인 선정 — 분석 B 결과 기반 자동 추출

위험요인 선정은 사람이 속성·위험값을 직접 매핑하지 않고, 분석 B 의 검증 결과(top\_attributes)에서 직접 계산한다('analysis\_b.extract\_risk\_attribute\_values'). 범주형 속성만 대상으로 하며, 세그먼트 내 해당 속성의 값별 이탈률 중 최댓값을 위험값으로 자동 채택한다(예: Contract 의 세 값 중 이탈률이 가장 높은 'Month-to-month'를 위험값으로 선택).

| 속성 종류                                             | 자동화 상태 | 비고                                                                     |
|---------------------------------------------------|--------|------------------------------------------------------------------------|
| 범주형 (Contract, InternetService, OnlineSecurity 등) | 자동 추출  | 분석 B 의 top_attributes 에 등장한 범주형 속성만 대상 — 분석 B 결과와 무관한 속성이 들어갈 수 없도록 설계 |

|                      |                      |                                                                                                     |
|----------------------|----------------------|-----------------------------------------------------------------------------------------------------|
| 연속형 (MonthlyCharges) | 자동화 대상에서 제외<br>(의도적) | '위험값'이 단일 값이 아니라 구간/방향의 문제라<br>별도 설계가 필요 — risk_count 의 설계<br>의도(이진 위험신호 보유개수)에 더 부합하도록<br>의도적으로 제외 |
|----------------------|----------------------|-----------------------------------------------------------------------------------------------------|

표 4-1. 위험요인 선정 자동화 범위

## 4.2 실행 결과

| 항목                         | 결과값                                                                        |
|----------------------------|----------------------------------------------------------------------------|
| 위험속성 3 종 (분석 B 결과에서 자동 추출) | Contract=Month-to-month, InternetService=Fiber optic,<br>OnlineSecurity=No |
| risk_count 단독 AUC          | 0.7828                                                                     |
| 순열검정 p-value               | 0.0000 (60 회 반복으로 자동 수렴)                                                   |
| 최고위험구간 (risk_count=3)      | n=1,240, 부트스트랩 40 회로 자동 수렴                                                 |
| 최고위험구간 이탈률(점추정)            | 58.31%                                                                     |
| 최고위험구간 이탈률 95% 신뢰구간        | [55.97%, 60.91%]                                                           |

표 4-2. 서브트랙 Q 실행 결과

risk\_count 단독 AUC(0.7828)가 분석 A 세그먼트단독 AUC(0.7223)보다 높게 나타났다. 다만 이는 risk\_count 가 분석 A 보다 우월하다는 의미가 아니라, 시간축(분석 A)과 속성결합(서브트랙 Q)이 서로 다른 각도에서 위험을 포착함을 보여주는 결과로 해석한다.

## 5. 예측모델 — 1·2·3 단계 비교

### 5.1 설계

| 단계   | 알고리즘    | 입력 피처                                  | 역할        |
|------|---------|----------------------------------------|-----------|
| 1 단계 | 로지스틱 회귀 | 전체속성 + tenure 원본 (34 개,<br>segment 제외) | 전통통계 비교군  |
| 2 단계 | XGBoost | 전체속성 + tenure 원본 (34 개,<br>segment 제외) | 현재 AI 비교군 |
| 3 단계 | XGBoost | 전체속성 + tenure 원본 + segment<br>(38 개)   | 메인 모델     |

|    |     |                         |         |
|----|-----|-------------------------|---------|
| 보조 | MLP | 2 단계와 동일 입력(34 개, 스케일링) | 딥러닝 비교군 |
|----|-----|-------------------------|---------|

표 5-1. 1·2·3 단계 + 보조 MLP 설계

XGBoost 하이퍼파라미터(max\_depth, n\_estimators, learning\_rate)는 2 단계 학습 시 GridSearchCV 로  
동시 자동 탐색되었으며(탐색 결과: max\_depth=3, n\_estimators=100, learning\_rate=0.05), 3 단계는  
동일 하이퍼파라미터를 물려받아 '성능 차이가 알고리즘 때문인지 접근법 때문인지' 혼동되지 않도록  
통제하였다.

1 단계(로지스틱 회귀)는 하이퍼파라미터 자동 탐색과 segment 입력 모두 의도적으로 제외하였다 —  
segment 자체가 데이터주도(분석 A)로 찾은 결과물이라, '사람이 정한 단순 함수형태에 의존하는 전통통계  
비교군'이라는 1 단계의 정의와 모순되기 때문이다. 분석 B·서브트랙 Q 에서 연속형 속성을 의도적으로  
자동화 대상에서 제외한 것과 같은 원칙(자동화 가능 여부가 아니라 설계 의도에 따라 범위를 정함)이다.

XGBoost 하이퍼파라미터 탐색은 2 단계에서 1 회만 수행하고 3 단계가 그대로  
물려받는다('xgboost\_kwargs') — 두 단계를 각각 따로 탐색했다면 같은 탐색 비용(48 가지 조합, 약 35 초)이  
두 번 들었을 것이다. '같은 설정으로 통제한다'는 실험설계 원칙과 '탐색 비용을 중복하지 않는다'는 비용  
원칙이 하나의 구조로 동시에 달성된다.

learning\_rate 은 이전에는 0.1 로 고정하고 탐색 대상에서 제외되어 있었으나, max\_depth·n\_estimators 와의  
자동화 수준 비일관성을 발견하여 같은 GridSearchCV 에 포함시켰다. 세 파라미터를 한 번에 탐색해  
파라미터 간 상호작용(예: learning\_rate 이 낮을 때 n\_estimators 를 더 키워야 하는 보정 관계)을 놓치지  
않도록 하였다.

## 5.2 성능 비교

| 단계               | Accuracy | Precision | Recall | F1     | F2     | ROC-AUC | PR-AUC | 임계값    |
|------------------|----------|-----------|--------|--------|--------|---------|--------|--------|
| 1 단계_로지스틱회귀      | 0.8107   | 0.6754    | 0.5526 | 0.6078 | 0.5734 | 0.8449  | 0.6416 | 0.5054 |
| 2 단계_XGBoost     | 0.7752   | 0.5569    | 0.7504 | 0.6393 | 0.7017 | 0.8454  | 0.6565 | 0.3345 |
| 3 단계_XGBoost(메인) | 0.7719   | 0.5512    | 0.7576 | 0.6381 | 0.7048 | 0.8457  | 0.6573 | 0.3268 |
| 보조_MLP           | 0.7563   | 0.5347    | 0.6310 | 0.5789 | 0.6091 | 0.8017  | 0.5738 | 0.4794 |

표 5-2. 1·2·3 단계 + 보조 MLP 평가지표 (Test 셋, n=2,113, 각 모델별 권장 임계값 기준, learning\_rate 자동탐색 반영)

⚠ Accuracy 는 참고용으로만 사용한다. 본 데이터는 이탈률 26.5%의 불균형 데이터로, 전부 비이탈로  
예측해도 Accuracy 73.5%가 나오기 때문이다.

### 5.2.1 평가지표 선정 근거 — F2-score

모델 튜닝 목적함수는 F2-score(Recall 에 2 배 가중치)이다. FN(이탈자를 놓치는 오류)이 FP(비이탈자를 오판하는 오류)보다 비용이 크다는 가정에 따른 것이다.

| 항목            | 값         | 비고                                                  |
|---------------|-----------|-----------------------------------------------------|
| FN 비용 근사 추정   | 1,438 / 명 | 이탈고객-비이탈고객 평균 tenure 차이<br>× 이탈고객 평균 MonthlyCharges |
| FP 비용(리텐션 비용) | 추정 불가     | 할인·CS 인력시간 등 회사 내부<br>운영정책 정보가 데이터에 부재              |
| 분류 임계값(메인 모델) | 0.3268    | PR 곡선에서 Recall 이 급격히 꺾이기<br>직전 지점                   |

표 5-3. F2-score 및 임계값 선정 근거

FP 비용을 비용행렬(cost matrix)에 직접 반영하려는 시도는 오히려 가정해야 할 숫자를 늘리는 역설로 확인되었다(F2 의 암묵적 비용비율 약 4:1 에서 FP 비용을 역산하면 364 가 나오나, 이는 F2 에서 거꾸로 끌어온 숫자일 뿐 새 정보가 아님). F2-score 를 그대로 유지하되, '정확한 비율을 몰라서 가정한다'가 아니라 'FP 비용에 필요한 정보가 구조적으로 데이터에 없음을 검증으로 확인했다'는 근거로 보강하였다.

### 5.3 세그먼트 라벨의 증분 기여 — 정직한 보고

세그먼트 라벨(segment)을 20 개 이상의 변수가 이미 포함된 모델에 추가했을 때의 증분 기여는 다음과 같다.

| 지표      | 2 단계(segment 미포함) | 3 단계(segment 포함) | 증분      |
|---------|-------------------|------------------|---------|
| F1      | 0.6393            | 0.6381           | -0.0012 |
| F2      | 0.7017            | 0.7048           | +0.0031 |
| ROC-AUC | 0.8454            | 0.8457           | +0.0003 |

표 5-4. 세그먼트 라벨 증분 기여 (F2-score 는 오히려 향상)

세그먼트 라벨을 추가했을 때 성능 지표 변화는 미미하다. 이는 세그먼트가 무의미하다는 뜻이 아니라, tenure 원본이 이미 세그먼트와 유사한 정보를 더 세밀한 형태로 담고 있어 증분 기여가 다중공선성과 유사한 양상으로 흡수된 현상이다. 세그먼트의 통계적 실재성에 대한 메인 증거는 분석 A 자체의 검증(2 장)에 있으며, 본 절의 비교는 예측모델 차원의 보조적 실용성 지표일 뿐이다.

### 5.4 세그먼트 피처 영향력 교차검증 — Feature Importance / SHAP

'세그먼트가 검증된 피처이므로 트리의 핵심 분기 기준이 될 것'이라는 가설을 실제 학습된 3 단계 모델의 트리 100 개를 직접 분석하여 검증하였다.

| 피처        | Gain Importance | Gain 순위 (전체 38 개 중) | SHAP 평균 영향력 | SHAP 순위 |
|-----------|-----------------|---------------------|-------------|---------|
| segment_0 | 0.0000          | 37 위                | 0.0000      | 37 위    |
| segment_1 | 0.0021          | 25 위                | 0.0031      | 24 위    |
| segment_2 | 0.0112          | 18 위                | 0.0019      | 25 위    |
| segment_3 | 0.0000          | 38 위                | 0.0000      | 38 위    |

표 5-5. segment\_\* 피처의 Gain Importance / SHAP 순위

전체 100 개 트리 중 segment\_\*가 루트(최상위) 노드의 분기 기준으로 선택된 사례는 0 건이다. Gain Importance 와 SHAP 라는 두 독립적인 측정 방식이 동일한 결론(영향력 낮음)을 보여 측정 우연이 아님을 교차검증하였다. 다만 이 결과는 예측모델 관점의 보조 지표이며, 세그먼트의 핵심 가치(통계적 실재성)는 분석 A 의 검증(2 장)에서 별도로 입증됨을 다시 강조한다.

## 5.5 모델 캘리브레이션

| 항목                | 값               |
|-------------------|-----------------|
| Test 셋 예측 이탈확률 평균 | 0.2650          |
| Test 셋 실제 이탈률     | 0.2655          |
| 차이                | 0.0005 (0.05%p) |

표 5-6. 메인 모델(3 단계) 캘리브레이션 검증

예측 확률의 평균과 실제 관측 이탈률이 거의 일치하여, 모델이 평균적으로 과대·과소 추정 없이 신뢰할 수 있는 확률 추정치를 산출함을 확인하였다.

## 6. 검증 자동화 — 엔지니어링 차별점

본 시스템의 핵심 차별점은 검증에 필요한 반복횟수·안전 마진까지 사람이 직접 정하지 않고, 데이터로부터 자동 루프 구조를 설계하고 통계학적 기법(Hanley-McNeil, Wilson, Clopper-Pearson)으로 멈춤 시점을 보완했다는 것이다. 그 결과 비용 절감과 성능·신뢰도 유지·향상을 동시에 달성하였다.

| 검증 항목 | 관행적 고정값 | 자동화 결과 (데이터가 결정) | 절감 비율 |
|-------|---------|------------------|-------|
|-------|---------|------------------|-------|

|                               |       |      |       |
|-------------------------------|-------|------|-------|
| 분석 A 부트스트랩 (전체데이터, n=4,930)   | 300 회 | 40 회 | 7.5 배 |
| 분석 A 순열검정 (전체데이터)             | 200 회 | 60 회 | 3.3 배 |
| 분석 B 부트스트랩 (세그먼트 0~3, 4 개 전부) | 300 회 | 40 회 | 7.5 배 |
| 분석 B 순열검정 (세그먼트 0~3, 4 개 전부)  | 200 회 | 60 회 | 3.3 배 |
| 서브트랙 Q 부트스트랩                  | 300 회 | 40 회 | 7.5 배 |
| 서브트랙 Q 순열검정                   | 500 회 | 60 회 | 8.3 배 |

표 6-1. 검증 반복횟수 자동화 결과 (Sequential Early Stopping) — 분석 B 는 4 개 세그먼트 모두 동일 수치로 수렴

분석 B 는 세그먼트 내부에서 다시 5-fold 교차검증을 수행해 표본부족 위험이 분석 A 보다 크다고 사전에 우려되었으나, 4 개 세그먼트 모두 분석 A 와 동일한 40 회(부트스트랩)·60 회(순열검정)로 자동 수렴하였다. 이는 표본 크기가 작아도 효과 크기(관측 통계량이 우연분포에서 벗어난 정도)가 충분히 크면 적은 반복으로도 안전 상한 조건을 만족함을 보여준다.

## 6.0 같은 철학의 확장 — XGBoost 하이퍼파라미터 자동화

검증 절차뿐 아니라 예측모델 자체의 하이퍼파라미터에도 동일한 원칙을 적용하였다.

max\_depth·n\_estimators 는 이미 GridSearchCV 로 자동 탐색하고 있었으나, learning\_rate 만 0.1 로 고정되어 있던 비일관성을 발견하고 같은 탐색에 편입하였다(5.1 절 참조).

| 파라미터          | 이전                | 현재                              | 비고         |
|---------------|-------------------|---------------------------------|------------|
| max_depth     | GridSearchCV 자동탐색 | GridSearchCV 자동탐색               | 변경 없음      |
| n_estimators  | GridSearchCV 자동탐색 | GridSearchCV 자동탐색               | 변경 없음      |
| learning_rate | 0.1 고정            | GridSearchCV 자동탐색<br>(결과: 0.05) | 이번에 자동화 편입 |

표 6-0. XGBoost 하이퍼파라미터 자동화 현황

새 파라미터를 한 번의 GridSearchCV 로 동시 탐색하여 파라미터 간 상호작용을 반영하였으며, 그 결과 2·3 단계 모두 ROC-AUC·F2-score 가 소폭 개선되었다(5.2 절 표 5-2 참조).

멈춤 판단은 두 조건의 결합으로 이루어진다: (1) Hanley-McNeil-Wilson 표준오차 공식으로 계산한 이론적 안전 상한보다 측정값이 좁아지는지, (2) 최근 측정값들이 더 이상 변하지 않는지(자기 안정성). 두 조건 중 하나가 연속 2 회 충족되면 멈춘다. 이 설계는 표본이 작고 불균형할수록 자동으로 더

신중하게(더 많이 반복) 동작한다는 것이 실측으로 확인되었다(작은 세그먼트 52 회 vs. 전체데이터 40 회).

## 6.1 안전 마진(structural\_gap)의 적응형 보정

위 자동화 루프가 사용하는 안전 상한 배율(structural\_gap, 초기값 1.3) 역시 고정값이었음을 발견하고, 추가 부트스트랩 실행 없이 운영 중 누적되는 관측치를 재사용하여 자동으로 보정하였다.

| 항목                        | 값                        |
|---------------------------|--------------------------|
| 콜드스타트 폴백값 (AUC 기반)        | 1.3                      |
| 콜드스타트 폴백값 (비율 기반, 서브트랙 Q) | 1.1                      |
| 적응형 보정 결과 (관측치 9 개 누적 후)  | 1.194 (고정값 대비 약 8% 더 정밀) |
| 추가 탐색비용                   | 0 (신규 부트스트랩 실행 없음)       |

표 6-2. structural\_gap 적응형 보정 결과

## 7. 운영 아키텍처 — 이원화 MLOps

| 구분    | 재학습 (train.py)                   | 추론 (predict.py)         |
|-------|----------------------------------|-------------------------|
| 실행 주기 | 표본이 충분히 쌓였을 때 (분석 A/B/Q 와 같은 묶음) | 자유 주기 (즉석 조회 등 언제든지 가능) |
| 학습 과정 | 있음 (모델 fit, 변환규칙 fit)            | 없음 (저장된 모델/규칙을 불러와 적용만) |
| 안정성   | 데이터 양에 영향받음                      | 항상 안정적 (학습이 없으므로)       |

표 7-1. 재학습/추론 분리 구조

부트스트랩 구현 시 Out-of-Bag(OOB) 방식을 필수로 적용한다. 복원추출 표본 안에서 다시 교차검증을 나누면 같은 행의 중복 복사본이 Train/Test 에 동시에 들어가 데이터 누수가 발생함을 실제로 발견(점추정값이 신뢰구간 하한보다 낮게 나오는 비정상 현상)하고 수정한 사례이다.

## 8. 한계 및 향후 과제

- 개입에 필요한 구체적 최소 리드타임(마케팅/CS 팀 대응 소요시간 기준)이 아직 미정
- 정확한 비용비율(FN:FP)은 가정값이며, 실제 비용 데이터 확보 시 비용행렬 적용으로 보강 가능

- PELT(통계적 변화점 탐지) 비교는 이론적 검토 단계에서 분포 가정 의존이라는 근본적 한계를 확인하여 메인 채택 후보에서 제외하였으며, 코드 기반 실측 비교는 미수행
- MLP 하이퍼파라미터(hidden\_layer\_sizes) 자동탐색은 우선순위가 낮아 보류

## 9. 결론

---

본 시스템은 시간(분석 A)·속성(분석 B)·결합신호(서브트랙 Q)라는 세 축을 각각 데이터 기반으로 독립 검증하고, 그 검증 과정 자체(반복횟수, 안전 마진)뿐 아니라 예측모델의 하이퍼파라미터(max\_depth, n\_estimators, learning\_rate)까지 자동화한 결과물이다. 예측모델(3 단계 XGBoost)은 ROC-AUC 0.8457, F2-score 0.7048 을 달성하였으며, 세그먼트 라벨의 직접적 성능 기여는 미미하지만 이는 분석 A 자체의 통계적 검증(세그먼트단독 AUC 0.7223,  $p=0.0000$ )으로 별도 입증되는 가치와 구분되는 보조 지표임을 분명히 한다. 모든 수치는 segment\_discovery/app.py 와 churn\_prediction/train.py 의 단일 실행(실행 ID 20260622\_171419)으로부터 재현 가능하다.