

모델 설계도

순열·부트스트랩 자동화 루프로 검증된 생애주기 세그먼트·위험속성·위험신호 분석 체계와
이원화 MLOps 아키텍처를 결합한 고객 이탈 예측 시스템

Customerang

팀장 오한빈

팀원 서유현 · 소성민 · 임정택

2026-06-23 | 실행 ID: 20260622_171419 오한빈 작성

0. 문서 개요

본 문서는 가입 고객 이탈 예측 시스템의 전체 모델 설계를 다이어그램·그래프 중심으로 정리한 설계도이다. 분석 A(생애주기 세그먼트)·분석 B(위험속성)·서브트랙 Q(위험신호 결합)와 예측모델(1·2·3 단계)이 어떻게 논리적으로 연결되는지, 그리고 각 단계에 적용된 자동화 루프·통계 기법·비용 개선 효과를 도식화하여 제시한다. 모든 수치는 실행 ID 20260622_171419 의 단일 실행 결과로부터 재현 가능하다.




그림 0-1. 전체 파이프라인 — 원본 데이터부터 예측 출력까지

핵심 설계 철학은 '데이터가 결정하도록 하고, 사람의 개입은 최소화한다'이다. 세그먼트 경계, 위험속성, 검증 반복횟수, 안전 마진, 모델 하이퍼파라미터, 비즈니스 비용 비대칭의 반영 위치까지 — 가능한 모든 지점에서 사람의 직감 대신 데이터·통계적 검증이 값을 결정하도록 설계하였다.

0.1 팀 소개 및 역할 분담

구성원	역할
오한빈 (팀장)	핵심 아이디어 제안(생애주기 세그멘테이션의 데이터 기반 자동화 루프화), 분석 A·분석 B·서브트랙 Q·예측모델 전체 기획·설계·파이프라인 구축 및 검증 구현, 전처리 구현, 프로젝트 전 과정 참여
서유현, 소성민, 임정택	팀장이 설계한 분석 A·분석 B·서브트랙 Q·예측모델 전 영역에 걸쳐 공동으로 실행데이터 검증 수행, Streamlit 대시보드 구현

표 0-1. 팀 Customerang 역할 분담

1. 문제 정의 — 왜 데이터 기반 경계가 필요한가

업계에서는 이미 신규고객·장기고객처럼 가입 후 경과월(tenure)에 따라 맞춤형 대응을 하고 있다. 그러나 '신규고객 90 일'과 같은 기준은 사람이 회계·계약상의 편의로 정한 임의값일 뿐, 실제 이탈 패턴이 바뀌는 지점과 일치한다는 근거가 없다 — 이를 기간 기반 고객 세그멘테이션(Duration-based Segmentation)의 불확실성이라 정의한다.

1.1 경계 탐지 방법론 선택

방향	방법	한계
(A) 머신러닝 기반	가지치기 회귀나무로 경계 탐지, 머신러닝·통계 기법으로 보완	alpha 탐색 그리드에 따른 미세한 민감성 — 보조 검증으로 해결 가능
(B) 통계 기법 기반	PELT(변화점 탐지) 등으로 경계를 먼저 탐지	경계 탐지 단계 자체가 이론적 분포 가정(BIC/AIC)에 의존 — 가정이 깨지면 그 위의 모든 보완이 연쇄적으로 흔들림

(B)는 경계 탐지 단계 자체에 이론적 가정이 들어가 있어 출발점의 불확실성이 상속되는 연속된 한계에 직면한다. 본 시스템은 (A)를 채택하였으며, PELT는 이론적 검토 단계에서 한계가 확인되어 코드 기반 비교는 수행하지 않았다.

2. 분석 A — 생애주기 세그먼트 경계 탐지

분석A — 4단계 검증 절차 (세그먼트 경계 탐지)

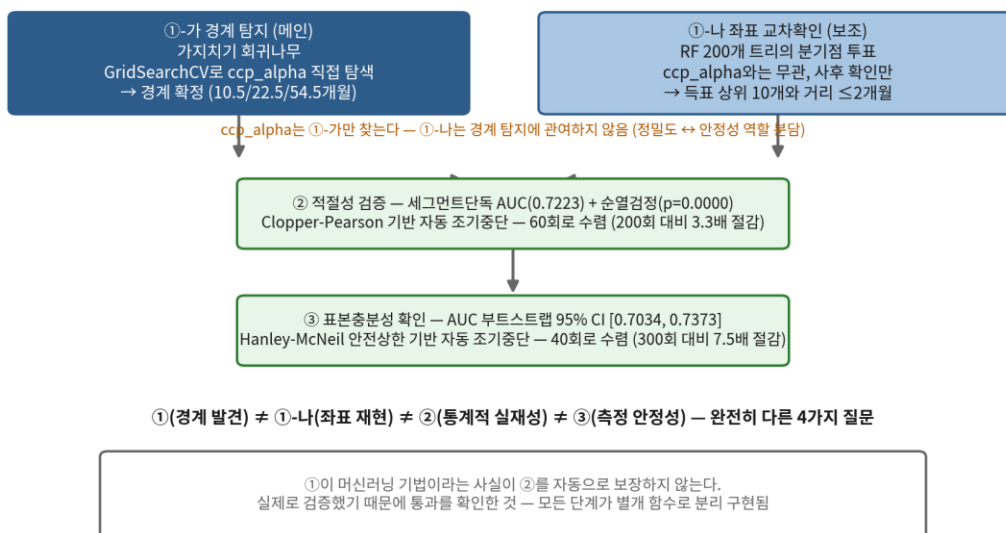


그림 2-1. 분석 A 4 단계 절차 — ①-가/①-나/②/③ 완전히 다른 4 가지 질문

ccp_alpha(가지치기 강도)는 GridSearchCV(①-가)만 탐색한다 — 랜덤포레스트(①-나)는 경계 탐지에 전혀 관여하지 않고, ①-가가 확정한 경계 좌표가 다른 알고리즘으로도 재현되는지 사후 확인하는 별개 절차다. 단일 결정나무는 좌표가 정밀하지만 alpha 탐색 그리드에 미세하게 민감하고, 랜덤포레스트는 여러 트리의 분기점 합의를 보여줘 좌표는 덜 정밀해도 시드 변경에 안정적이다 — 정밀도와 안정성의 역할 분담이다.




그림 2-2. tenure 별 이탈률 곡선과 발견된 경계 — 관행 기준(90 일)과의 비교

발견된 경계(10.5/22.5/54.5 개월)는 관행적 기준(90 일≈3 개월)과 전혀 다른 위치에서 나타난다. 세그먼트 0(0~10.5 개월)의 이탈률 49.7%는 전체 평균(26.5%) 대비 23.2%p 높은 가장 위험한 구간이다.

항목	결과값
발견된 경계 (K=4)	10.5 / 22.5 / 54.5 개월
세그먼트단독 AUC	0.7223, 95% CI [0.7034, 0.7373]
순열검정 p-value	0.0000 (60 회 반복, 200 회 고정값 대비 3.3 배 절감)
부트스트랩 반복	40 회 (300 회 고정값 대비 7.5 배 절감)

표 2-1. 분석 A 실행 결과 요약

3. 분석 B — 세그먼트별 위험속성 탐지

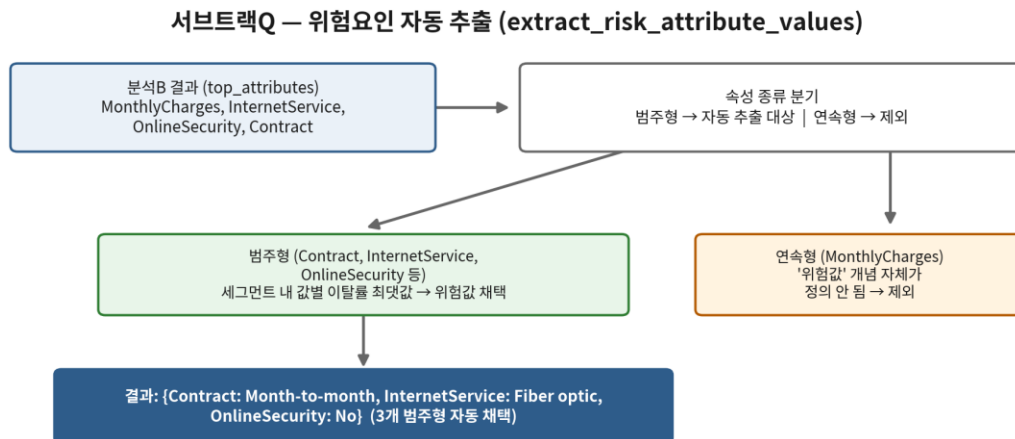
분석 A 의 2 단 구조(머신러닝 탐지 → 통계적 검증)를 세그먼트 내부의 여러 속성에 동일하게 재사용한다. 위험속성의 개수 자체도 사람이 'top 2 개만' 같은 고정 개수로 제한하지 않고, 결정나무의 feature_importances_ 중 0 보다 큰 속성을 전부 자동 채택한다.

세그먼트	이탈률	주요 위험속성	속성기반 AUC
0 (0~10.5 개월)	49.7%	MonthlyCharges, InternetService, OnlineSecurity	0.7575
1 (10.5~22.5 개월)	29.8%	MonthlyCharges	0.7315
2 (22.5~54.5 개월)	19.2%	Contract, MonthlyCharges	0.7903
3 (54.5 개월+)	8.6%	Contract, MonthlyCharges	0.7677

표 3-1. 세그먼트별 위험속성 탐지 결과 (4 개 세그먼트 모두 부트스트랩 40 회·순열검정 60 회로 자동 수렴)

신규 고객(segment_0)은 서비스 구성(인터넷·보안서비스)이 핵심 위험신호이고, 중장기 고객(segment_2·3)은 계약형태(Contract)로 전환된다 — 같은 속성이라도 생애주기 맥락에 따라 영향력이 다르다는 분석 B 의 핵심 가치를 실증한다.

4. 서브트랙 Q — 위험신호 누적 분석



분석B 결과와 무관한 속성이 risk_attribute_values에 섞일 수 없도록 — 사람이 손으로 옮겨 적는 단계를 제거

그림 4-1. 위험요인 자동 추출 절차 — 범주형/연속형 분기

위험요인 선정은 사람이 속성·위험값을 직접 매핑하지 않고 분석 B 의 검증 결과(top_attributes)에서 직접 계산한다. 범주형 속성만 대상으로 하며, 세그먼트 내 해당 속성의 값별 이탈률 중 최댓값을

위험값으로 자동 채택한다. 연속형 속성(MonthlyCharges)은 '위험값'이라는 개념 자체가 정의되지 않아 의도적으로 제외하였다 — risk_count 의 설계 의도(이진 위험신호의 보유개수)에 더 부합하는 선택이다.

항목	결과값
위험속성 3 종 (자동 추출)	Contract=Month-to-month, InternetService=Fiber optic, OnlineSecurity=No
risk_count 단독 AUC	0.7828
순열검정 p-value	0.0000 (60 회, 500 회 고정값 대비 8.3 배 절감)
최고위험구간 (risk_count=3)	n=1,240, 이탈률 58.31%, 95% CI [55.97%, 60.91%]

표 4-1. 서브트랙 Q 실행 결과

분석A·B·서브트랙Q 3자 비교 — 같은 척도로 나란히 비교





그림 4-2. 분석 A·B·서브트랙 Q 3자 비교 — 같은 척도(이탈률·lift)로 나란히 비교

세 분석을 따로 보지 않고 같은 척도로 나란히 비교해야 '어느 유형이 더 위험한가'를 판단할 수 있다. 위험신호를 동시에 보유한 고객 집단(risk_count)이 시간(분석 A)이나 단일 속성결합(분석 B)보다 더 강한 lift 를 보인다.

5. 예측모델 — 1·2·3 단계 비교 설계



세그먼트 라벨 포함(3단계)으로도 성능은 거의 동일 — 메인 증거는 분석A 자체 검증, 성능 비교는 보조 지표

그림 5-1. 1·2·3 단계 비교 구조와 Test 셋 성능

1 단계는 '사람이 정한 단순 함수형태에 의존하는 전통통계 비교군'이라는 역할을 위해 하이퍼파라미터 자동 탐색과 segment 입력을 의도적으로 제외한다. 2·3 단계는 GridSearchCV 로 max_depth·n_estimators·learning_rate 을 1 회만 동시 탐색하고 3 단계가 그대로 물려받는다 — 두 단계를 각각 탐색했다면 같은 비용(48 가지 조합, 약 35 초)이 두 번 들었을 것이다. '같은 설정으로 통제한다'는 실험설계 원칙과 '탐색 비용을 중복하지 않는다'는 비용 원칙이 하나의 구조로 동시에 달성된다.

5.1 세그먼트 라벨 영향력 — Feature Importance 교차검증




그림 5-2. 3 단계 모델 Feature Importance — segment 피쳐 순위

segment_*가 검증된 피쳐이므로 트리의 핵심 분기 기준이 될 것이라는 가설을 실제 트리 100 개를 직접 분석하여 검증하였다. 전체 100 개 트리 중 segment_*가 루트(최상위) 노드의 분기 기준으로 선택된 사례는 0 건이며, Gain Importance와 SHAP 두 독립적인 측정 방식이 동일한 결론(영향력 낮음)을 보였다. 다만 이는 예측모델 관점의 보조 지표이며, segment의 핵심 가치(통계적 실재성)는 분석 A의 검증(2 장)에서 별도로 입증됨을 다시 강조한다.

5.2 FN 비용 비대칭의 반영 위치 — 이중 보정 중복효과 실측

F2-score로 'FN이 더 비싸다'는 비즈니스 가정을 평가 단계에 반영하기로 정했지만, 같은 보정을 학습 단계(class_weight/scale_pos_weight)에서 한 번 더 적용할 수도 있었다. 두 보정 장치가 같은 방향(Recall 상승)으로 작동하는지 직접 실측하여, 어느 단계에서만 반영해야 하는지를 데이터로 결정하였다.





그림 5-3. 학습 보정 vs 평가 보정 — 중복효과 실측 비교

권장 임계값만으로 이미 Recall 이 충분히 보정되고 있어(0.734 vs 0.726, 거의 동일), 학습 보정을 추가하면 같은 효과가 중복 적용되어 해석이 불분명해진다(둘 다 적용 시 0.806 까지 과도하게 치우침). '어떤 하나의 변화가 결과에 미친 영향을 분리해서 봐야 한다'는 실험설계 원칙에 따라 모든 단계(1·2·3·MLP)의 학습은 중립적으로 두고, 비즈니스 비용 비대칭은 오직 평가 단계의 임계값 선택에서만 반영한다.

6. 검증 자동화 — Sequential Early Stopping

순열검정·부트스트랩이 몇 번 반복되어야 충분한지를 고정값이 아니라 통계적 안전 상한으로 직접 판단하는 자동 루프를 설계하였다.

Sequential Early Stopping — 멈춤 판단 루프



최소 30회 이전에는 체크하지 않음(표본부족 무의미 방지) — 표본·효과크기에 따라 안전상한이 다르게 계산되어 멈춤시점도 동적으로 결정

그림 6-1. Sequential Early Stopping 멈춤 판단 루프

검증 반복횟수 자동화 — Sequential Early Stopping 효과




그림 6-2. 검증 반복횟수 자동화 효과 — 고정값 대비 3.3~8.3 배 절감

멈춤 판단은 두 조건의 결합이다: (1) Hanley-McNeil·Wilson 표준오차 공식으로 계산한 이론적 안전 상한보다 측정값이 좁아지는지, (2) 최근 5회 측정값이 5% 이내로 거의 변하지 않는지. 두 조건 중 하나가 연속 2회 충족되면 멈춘다. 딥러닝의 조기 종료(Early Stopping)가 경험적 판단(validation loss 정제)에 의존하는 반면, 본 시스템은 이론적 상한선을 먼저 계산해두고 실측 안정성과 함께 충족해야 멈추도록 설계하여 — 멈춤 판단 방식 자체를 통계적으로 검증 가능한 형태로 끌어올렸다.

6.1 실측 재확인 — 공통 하한선 도달의 의미

분석 A·분석 B(4 개 세그먼트)·서브트랙 Q 전부 부트스트랩 40 회·순열검정 60 회로 수렴하였다. 표본 크기가 749~4,930 으로 6 배 넘게 차이 나는데도 공통된 지점에서 멈추는 이유를 진단 데이터로 직접 확인하였다. 안전 상한 자체는 표본 크기·효과크기에 따라 실제로 다르게 계산되나(케이스별 0.045~0.138, 약 3 배 차이), 이번 데이터의 모든 케이스가 AUC 0.72~0.79 대의 비교적 강한 신호라 체크 가능한 최소 시점(30 회)에 이미 그 느슨한 상한을 통과하였다. 비용 절감 효과(3.3~8.3 배)는 명확하나, '작은 표본은 더 신중하게 반복한다'는 차별화 서사는 이번 실행에서는 재현되지 않았음을 정직하게 밝힌다.

6.2 안전 마진(structural_gap)의 적응형 보정

자동 루프가 멈춤 여부를 판단할 때 쓰는 안전 마진(structural_gap, 초기값 1.3) 역시 사람이 정한 파라미터였음을 발견하고 데이터로 자동 보정하였다. 안전 마진을 정확히 추정하려고 매번 별도로 부트스트랩을 추가 실행하면 검증 비용을 줄이려고 만든 루프가 다시 비용을 키우는 역설에 빠지므로, 루프가 운영되는 과정에서 자연스럽게 쌓이는 관측치를 추가 비용 없이 재사용한다. 관측치 9 개 누적 후 자동 보정된 마진은 1.194 로, 고정값(1.3)보다 약 8% 더 타이트하게(정밀하게) 조정되었다.

7. 자동화 전체 항목 정리

자동화 대상	무엇을 사람이 정하지 않게 했는가	근거 위치
가지치기 강도(ccp_alpha)	세그먼트 경계의 위치와 개수(K)	2 장
RF 보조검증 트리개수	경계 좌표 교차확인에 쓰는 트리 개수	2 장
분석 B 위험속성 개수	top_n 고정 대신 importance>0 전부 채택	3 장
XGBoost 하이퍼파라미터	max_depth·n_estimators·learning_rate	5 장
서브트랙 Q 위험속성 매핑	범주형 위험값을 분석 B 결과에서 자동 추출	4 장
불균형 보정 반영 위치	학습 단계 vs 평가 단계, 중복효과 실측으로 결정	5.2 절
검증 반복횟수	순열검정·부트스트랩 반복횟수 자체	6 장
안전 마진(structural_gap)	부트스트랩 안전 상한 배율 자체	6.2 절

표 7-1. 본 시스템에서 자동화한 전체 항목

자동화가 항상 비용을 줄이는 방향인 것은 아니다. ccp_alpha 탐색은 비용을 아끼려 후보를 일부만 보면 그리드 민감성이 생기는 것이 실측으로 확인되어, 오히려 전체 후보를 다 탐색하도록(비용을 늘리는 방향으로) 자동화하였다. 공통 원칙은 '사람이 임의로 정하지 않는다'이며 '반복을 무조건 줄인다'가 아니다.

8. 운영 아키텍처 — 이원화 MLOps

구분	재학습 (train.py)	추론 (predict.py)
실행 주기	표본이 충분히 쌓였을 때 (분석 A/B/Q 와 같은 묶음)	자유 주기 (즉석 조회 등 언제든지 가능)
학습 과정	있음 (모델 fit, 변환규칙 fit)	없음 (저장된 모델/규칙을 불러와 적용만)
안정성	데이터 양에 영향받음	항상 안정적 (학습이 없으므로)

표 8-1. 재학습/추론 분리 구조

부트스트랩 구현 시 Out-of-Bag(OOB) 방식을 필수로 적용한다. 복원추출 표본 안에서 다시 교차검증을 나누면 같은 행의 중복 복사본이 Train/Test 에 동시에 들어가 데이터 누수가 발생함을 실제로 발견(점추정값이 신뢰구간 하한보다 낮게 나오는 비정상 현상)하고 수정한 사례이다.

9. 결론

본 시스템은 시간(분석 A)·속성(분석 B)·결합신호(서브트랙 Q)라는 세 축을 각각 데이터 기반으로 독립 검증하고, 그 검증 과정 자체(반복횟수, 안전 마진)뿐 아니라 예측모델의 하이퍼파라미터와 비즈니스 비용 비대칭의 반영 위치까지 자동화한 결과물이다. 예측모델(3 단계 XGBoost)은 ROC-AUC 0.8457, F2-score 0.7048 을 달성하였으며, 세그먼트 라벨의 직접적 성능 기여는 미미하지만 이는 분석 A 자체의 통계적 검증(세그먼트단독 AUC 0.7223, $p=0.0000$)으로 별도 입증되는 가치와 구분되는 보조 지표임을 분명히 한다.

- 개입에 필요한 구체적 최소 리드타임(마케팅/CS 팀 대응 소요시간 기준)이 아직 미정
- 정확한 비용비율(FN:FP)은 가정값이며, 실제 비용 데이터 확보 시 비용행렬 적용으로 보강 가능
- 서브트랙 Q 의 위험요인은 범주형만 자동 추출됨 — 연속형(MonthlyCharges) 속성의 위험값 정의는 별도 설계 필요
- PELT 비교는 이론적 검토 단계에서 분포 가정 의존 한계를 확인하여 메인 채택 후보에서 제외, 코드 기반 실측 비교는 미수행